

ACCURATEZZA DI UN RISULTATO

Errore assoluto : $E_a = |x_{\text{ris approssimato}} - x_{\text{risatto}}|$

Errore relativo : $E_r = \frac{|x_{\text{ris approssimato}} - x_{\text{risatto}}|}{|x_{\text{risatto}}|}$ $|x_{\text{risatto}}| \neq 0$

Errore percentuale : $E_p = (E_r \cdot 100) \%$

RAPPRESENTAZIONE DEI NUMERI IN MEMORIA

Vengono rappresentati in forma binaria (base 2)

Fissato un numero $\beta \in \mathbb{N}$, con $\beta > 1$, rappresentiamo nella base β un numero pedonale $d \in \mathbb{R}$

$$d = \pm (d_0.d_1.d_2 \dots d_p.d_{p+1} \dots)_\beta = \sum_{k=0}^p d_k \beta^{p-k} + \sum_{k=p+1}^{\infty} d_k \beta^{-k}$$

NORMALIZZATA $d = \pm (0.d_1.d_2 \dots)_\beta$

NUMERI INTERI

Rappresentazione in modulo e segno

Il modo più semplice per rappresentarli in memoria è quello di anticipare un bit che vale 0 se è positivo, 1 se negativo

Con N bit si possono rappresentare tutti i numeri da $[-(2^{N-1}-1), 2^{N-1}-1]$

NUMERI REALI

Si usa il metodo delle moltiplicazioni successive

$$(0.2)_{10} = (0.\overline{0010})_2$$

$$\begin{cases} 0.2 \times 2 = 0.4 \\ 0.4 \times 2 = 0.8 \\ 0.8 \times 2 = 1.6 \\ 0.6 \times 2 = 1.2 \\ 0.2 \times 2 = 0.4 \end{cases} \quad \begin{array}{l} \text{perde intesa} \\ 0 \\ 0 \\ 1 \\ 1 \\ 0 \end{array}$$

Rappresentazione scientifica moltiplicata di un numero reale :

$$\text{ogni } x \in \mathbb{R} \text{ può essere espresso come } x = \pm (0.d_1.d_2 \dots)_\beta^p = \pm \sum_{i=-\infty}^{\infty} (d_i \beta^{-i}) \beta^p$$

il numero $0.d_1.d_2.d_3 \dots$ viene detto mantissa di x , β^p è lo spostamento

p è detta caratteristica di x (o esponente), β è la base, d_i sono le cifre di rappresentazione

$$\begin{cases} p \in \mathbb{N} \\ 0 \leq d_i \leq \beta-1 \\ d_i \neq 0 \end{cases}$$

SISTEMA FLOATING POINT

Si definisce un insieme dei numeri macchina (floating-point) con t cifre significative, base β e range (L, U)

$$F(\beta, t, L, U) = \{0\} \cup \{x \in \mathbb{R} = \text{sign}(x) \beta^p \sum_{i=0}^{t-1} d_i \beta^{-i}\}$$

$$\begin{cases} t, \beta \in \mathbb{N} & \beta \geq 2 \\ 0 \leq d_i \leq \beta-1 & d_i \neq 0 \\ L \leq p \leq U & \end{cases}$$

L ed U sono dello stesso ordine di grandezza.

t rappresenta il numero di cifre della mantissa (la precisione)

► $F(2, 24, -128, 127)$ precisione singola, 32 bit di cui 24 per la mantissa, 8 all'esponente

► $F(2, 53, -1024, 1023)$ precisione doppia, 64 bit di cui 53 per la mantissa, 11 all'esponente

ERRORE DI RAPPRESENTAZIONE

Errore assoluto di arrotondamento: $|fl(x) - x| < \beta^{p-t}$

Errore relativo di arrotondamento: $\frac{|fl(x) - x|}{|x|} < \frac{\epsilon}{2} \beta^{1-t}$

$$\left. \begin{array}{l} \text{exp} = \frac{1}{2} \beta^{1-t} \text{ è della precisione machine} \\ \text{exp è il più piccolo numero machine positivo} \\ \text{Tale che } fl(1+exp) > 1 \end{array} \right\}$$

Poiché $F \subseteq \mathbb{R}$, le operazioni sono definite anche per operandi in F , ma soltanto i risultati $\notin F$, quindi il risultato esatto è confrontato ad un numero che sta in F

operazione aritmetica reale $\circ : \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{R}$

operazione floating-point $\odot : F \times F \rightarrow F \quad x \odot y = fl(x \cdot y)$

NB ogni operazione provoca un errore molto piccolo detto di arrotondamento

$$\left| \frac{(x \odot y) - (x \cdot y)}{x \cdot y} \right| < \text{exp}$$

ERRORE NEL CALCOLO NUMERICO

di misura: dovuto alle imperfezioni dell'strumento di misura dei dati del problema

di truncamento: quando un procedimento infinito viene realizzato come finito

algoritmico: dovuto al propagarsi di errori di arrotondamento nelle singole operazioni in un procedimento complesso

iniziale: i dati del problema non sempre appartengono ad F e quindi vengono approssimati

RISOLUZIONE DI SISTEMI LINEARI

TEOREMA: Se A una matrice $m \times m$, allora sono equivalenti:

① $Ax=0$ ha una sola soluzione: $x=0$

② \forall vettore b , $Ax=b$ ha una sola soluzione

③ A è non singolare (determinante $\neq 0$)

Per risolvere un sistema lineare, possiamo utilizzare 2 tipi di metodi:

- **DIRETTI**: soluzione calcolata in un certo numero di passi finiti

- **ITERATIVI**: calcolo di una soluzione come approssimazione di una successione x_k (Adatti a sistemi grandi)

Sistema triangolare superiore

$$\begin{pmatrix} a_{1,1} & a_{1,2} & \dots & a_{1,m} \\ 0 & a_{2,2} & \dots & \vdots \\ \vdots & & & \\ 0 & \dots & 0 & a_{m,m} \end{pmatrix} \begin{pmatrix} x_1 \\ \vdots \\ x_m \end{pmatrix} = \begin{pmatrix} b_1 \\ \vdots \\ b_m \end{pmatrix}$$

partendo dal basso

$$a_{m,m} \cdot x_m = b_m \rightarrow x_m = \frac{b_m}{a_{m,m}}$$

↑ Sostituzioni successive
verso l'alto

Sistema triangolare inferiore

$$\begin{pmatrix} a_{1,1} & 0 & \dots & 0 \\ a_{2,1} & \dots & \vdots & 0 \\ \vdots & & & 0 \\ a_{m,1} & \dots & a_{m,m} \end{pmatrix} \begin{pmatrix} x_1 \\ \vdots \\ x_m \end{pmatrix} = \begin{pmatrix} b_1 \\ \vdots \\ b_m \end{pmatrix}$$

$$a_{1,1} \cdot x_1 = b_1 \rightarrow x_1 = \frac{b_1}{a_{1,1}}$$

↓ Sostituzioni successive
verso il basso

Metodo di eliminazione di Gauss

Si eliminano le incognite in modo sistematico per trasformare il sistema lineare in uno equivalente a scalo cui forme triangolare superiore.

Custo computazionale $O(n^2/2)$

$$Ax = b \xrightarrow{\text{GAUSS}} Rx = y \quad \text{dove } R \text{ è triangolare superiore}$$

Fattorizzazione LR

Operazioni necessarie a trasformare A nella matrice triangolare superiore R . $A =$

$$\begin{pmatrix} 2 & 1 & 1 & 0 \\ 4 & 3 & 3 & 1 \\ 8 & 7 & 9 & 5 \\ 6 & 7 & 9 & 8 \end{pmatrix}$$

PASSO 1

$$\text{Costruisco } L_1 = \begin{pmatrix} 1 & 0 & 0 & 0 \\ -2 & 1 & 0 & 0 \\ -4 & 0 & 1 & 0 \\ -3 & 0 & 0 & 1 \end{pmatrix}$$

tutti 1 sulla diagonale. Nella prima colonna c'è il risultato della divisione di tutti i termini della colonna con il primo termine, cominciando da

Si moltiplice L_1 per A

$$\begin{pmatrix} 1 & & & \\ -2 & 1 & & \\ -4 & & 1 & \\ -3 & & & 1 \end{pmatrix} \cdot \begin{pmatrix} 2 & 1 & 1 & 0 \\ 4 & 3 & 3 & 1 \\ 8 & 7 & 9 & 5 \\ 6 & 7 & 9 & 8 \end{pmatrix} = \begin{pmatrix} 2 & 1 & 1 & 0 \\ 0 & 1 & 1 & 1 \\ 0 & 3 & 5 & 5 \\ 0 & 4 & 6 & 8 \end{pmatrix}$$

$$L_1 \cdot A = A_1$$

PASSO 2

Costruisco L_2 nello stesso modo, partendo da A_1 .

$$L_2 = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & -3 & 1 & 0 \\ 0 & -6 & 0 & 1 \end{pmatrix}$$

Moltiplico L_2 per A_1 e ottengo A_2 =

$$\begin{pmatrix} 2 & 1 & 1 & 0 \\ 0 & 1 & 1 & 1 \\ 0 & 0 & 2 & 2 \\ 0 & 0 & 2 & 6 \end{pmatrix}$$

PASSO 3

Costruisco L_3 nello stesso modo

$$L_3 = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

e lo moltiplico per A_3 , ottenendo

$$R = \begin{pmatrix} 2 & 1 & 1 & 0 \\ 0 & 1 & 1 & 1 \\ 0 & 0 & 2 & 2 \\ 0 & 0 & 0 & 2 \end{pmatrix}$$

$$L_3 \cdot L_2 \cdot L_1 \cdot A = R$$

$$\text{Di conseguenza: } A = LR \quad \text{con} \quad L = L_1^{-1} \cdot L_2^{-1} \cdot L_3^{-1}$$

$$\text{calcolando le inverse di } L_1, L_2, L_3 \text{ e moltiplicandole, ottengo } L = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 2 & 1 & 0 & 0 \\ 4 & 3 & 1 & 0 \\ 3 & 6 & 1 & 1 \end{pmatrix}$$

Le complessità della fattorizzazione LR è $\mathcal{O}(n^3)$

Non sempre la fattorizzazione LR è fattibile.

$$A = \begin{pmatrix} 10^{-20} & 1 \\ 1 & 1 \end{pmatrix} = L \cdot R$$

Con la fattorizzazione UR trovo

$$L = \begin{pmatrix} 1 & 0 \\ 10^{-20} & 1 \end{pmatrix}$$

$$R = \begin{pmatrix} 10^{-20} & 1 \\ 0 & 1 - 10^{-20} \end{pmatrix}$$

Se sorpasso $F(2,53, -1024, 123)$
con precisione 10^{-16} , perdo l'1

$$R \text{ diretta } \tilde{R} = \begin{pmatrix} 10^{-20} & 1 \\ 0 & -10^{-20} \end{pmatrix}$$

mentre $L = \tilde{L}$

$$\tilde{L} \cdot \tilde{R} = \begin{pmatrix} 10^{-20} & 1 \\ 1 & 0 \end{pmatrix}$$

quindi \tilde{L}, \tilde{R} non sono la fattorizzazione LR di A

OSSERVAZIONI

In alcune matrici non si riesce a calcolare la fattorizzazione LR . Anche se \tilde{L}, \tilde{R} sono vicine ad LR , i loro prodotti possono essere molto distanti

$$\tilde{L} = L + \Delta L$$

$$\tilde{R} = R + \Delta R$$

$\Delta L, \Delta R$ erano

$$\tilde{L} \cdot \tilde{R} = (\underbrace{LR}_{A} + L \Delta R + \Delta L R + (\Delta L \Delta R)) \neq A = A + \Delta A$$

errore piccolo e trascurabile

La fattorizzazione LR è un algoritmo INSTABILE.

Si introduce quindi la fattorizzazione LU con PIVOT

pivot

$$\begin{pmatrix} x & x & x & \dots & x \\ \dots & x & \dots & x \\ x & x & \dots & x \\ \vdots & \vdots & \ddots & \vdots \\ x & x & \dots & x \end{pmatrix}$$

Se $a_{k,k} = 0$ scelgo un $i \neq k$ con $j > k$ e scambio le righe

PIVOTING PARZIALE

Nel prolo Scambiare le righe, scelgo come pivot nella colonna sottostante l'elemento max im valore assoluto \rightarrow ho più stabilità

$$A = \begin{pmatrix} 2 & 1 & 1 & 0 \\ 4 & 3 & 3 & 1 \\ 8 & 7 & 9 & 5 \\ 6 & 7 & 9 & 8 \end{pmatrix}$$

$$\begin{pmatrix} & 1 \\ 1 & & \\ & & 1 \end{pmatrix} \cdot \begin{pmatrix} 2 & 1 & 1 & 0 \\ 4 & 3 & 3 & 1 \\ 8 & 7 & 9 & 5 \\ 6 & 7 & 9 & 8 \end{pmatrix} = \begin{pmatrix} 8 & 7 & 9 & 5 \\ 4 & 3 & 3 & 1 \\ 2 & 1 & 1 & 0 \\ 6 & 7 & 9 & 8 \end{pmatrix} = A_1$$

Si crea la matrice P_1 che è chiamata di permutazione. È la matrice identità

con le righe che devono scambiare i coefficienti

A questo punto uso L e nello stesso modo della fattorizzazione LR

$$\begin{pmatrix} 1 & 0 & 0 & 0 \\ -\frac{1}{2} & 1 & 0 & 0 \\ -\frac{1}{4} & 0 & 1 & 0 \\ -\frac{3}{4} & 0 & 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} 8 & 7 & 9 & 5 \\ 4 & 3 & 3 & 1 \\ 2 & 1 & 1 & 0 \\ 6 & 7 & 9 & 8 \end{pmatrix} = L_1 \cdot A_1 = A_2$$

Proseguo fino ad ottenere $L_3 \cdot A_3 = R$

Sistema lineare

$$Ax=b \quad \Rightarrow \quad PAx=Pb \quad \text{con } P \text{ matrice di permutazione}$$

$$LRx=Pb \quad \Rightarrow \quad \begin{cases} Ly = Pb \\ Rx = y \end{cases}$$

Qualunque matrice A non singolare ammette fattorizzazione LR con pivotage parziale

Caso generale $Ax=b$

Calcolab P, L, R tale da $PA = LR$

Sistema Triangolare inferiore $Ly = z$

$$PA = Pb \quad \text{quindi} \quad z = Pb$$

Sistema Triangolare superiore $Rx = y$

NORME

Una norma è una funzione $\|\cdot\| : \mathbb{C}^m \rightarrow \mathbb{R}$ che associa un valore reale ≥ 0 (lunghezza) a ogni vettore

$$\forall x, y \in \mathbb{C}^m, \forall d \in \mathbb{C}$$

- $\|x\| \geq 0$ e $\|x\|=0$ se $x = \vec{0}$

- $\|x+y\| \leq \|x\| + \|y\|$

- $\|d \cdot x\| = |d| \cdot \|x\|$

- $\|x\|_p = \left(\sum_{i=1}^m |x_i|^p \right)^{1/p}$ con $1 \leq p \leq \infty$

\rightarrow Norma EUCLIDEA: $\|x\|_2 = \left(\sum_{i=1}^m |x_i|^2 \right)^{1/2}$

- $\|x\|_\infty = \max_{1 \leq i \leq m} |x_i|$

- $\|x\|_1 = \sum |x_i|$

Per i vettori $\|x\|_1 \geq \|x\|_2 \geq \|x\|_\infty$

NORMA DI MATRICI

- $\|AB\| \leq \|A\| \|B\|$
- $\|I\| = 1$
- $\|A\| \geq 0, \|A\| = 0 \Leftrightarrow A = 0$
- $\|A+B\| \leq \|A\| + \|B\|$
- $\|dA\| = |d| \cdot \|A\|$

$$\bullet \|A\|_1 = \max_{1 \leq j \leq m} \sum_{i=1}^m |a_{ij}|$$

Sommo tutti gli elementi in un'ordine di una colonna \rightarrow prendo le somme massime tra tutte le colonne $A = \begin{pmatrix} -1 & 2 \\ 3 & -6 \end{pmatrix}$ 1^o colonna $\rightarrow 4$ 2^o colonna $\rightarrow 6$

$$\bullet \|A\|_\infty = \max_{1 \leq i \leq m} \sum_{j=1}^m |a_{ij}|$$

Come quelle precedenti, ma sommo gli elementi delle righe

$$A = \begin{pmatrix} -1 & 2 \\ 3 & -6 \end{pmatrix} \quad 1^{\circ} \text{riga} \rightarrow 3 \quad 2^{\circ} \text{riga} \rightarrow 7$$

NORMA DI FROBENIUS

$$\|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n (a_{ij})^2}$$

Somma di tutti gli elementi al quadrato sotto radice

$$A = \begin{pmatrix} -1 & 2 \\ 3 & -6 \end{pmatrix} \quad \|A\|_F = \sqrt{(-1)^2 + (2)^2 + (3)^2 + (-6)^2} = \sqrt{30}$$

$$\bullet \|A\|_2 = \sqrt{\rho(A^T \cdot A)}$$

dove ρ indica il raggio spettrale di una matrice = max autovalore in moduli

$$\rho(A^T \cdot A) = \max \text{modulo delle autovalori della matrice prodotto } A^T \cdot A$$

PROBLEMA BEN CONDIZIONATO

A piccole variazioni dei dati, corrispondono piccole variazioni dei risultati

errore dati
errore risultati

$$\Delta r \approx \Delta w$$

Se x^* tale che $Ax^* = b$. Si studia la soluzione del sistema perturbato

$$(A + \Delta A) \tilde{x} = b + \Delta b$$

$$\tilde{x} = x^* + \Delta x$$

Il condizionamento è legato all'errore INERENTE (causato dall'errore di rappresentazione o sui dati $\approx 10^{-16}$)

E_I : errore inerente, E_R : errore rappresentazione

Se $E_I \gg E_R$ molto più grande in ordine di grandezza \rightarrow problema mal condizionato

Se $E_I \approx E_R$ è più o meno lo stesso ordine di grandezza \rightarrow problema ben condizionato

Dati $Ax = b$ e $(A + \Delta A)(x + \Delta x) = b + \Delta b$, per stimare l'errore inerente $E_r = \frac{\|\Delta x\|}{\|x\|}$

Supponiamo di perturbare solo il termine noto

$$\Delta A=0 \quad e \quad \delta b \neq 0$$

$$A\overset{1}{x}=b$$

$$A(x+\delta x) = b + \delta b$$

$$2-1 = A\delta x = \delta b$$

$$\|A\| \|\delta x\| = \|\delta b\|$$

$$\text{D'altra parte } Ax=b \rightarrow \|b\| = \|Ax\| \leq \|A\| \|x\|$$

$$\Rightarrow \frac{1}{\|x\|} \leq \frac{\|A\|}{\|b\|}$$

numero di condizionamento

$$\frac{\|\delta x\|}{\|x\|} \leq \frac{\|A^{-1}\| \|A\|}{\frac{\|\delta b\|}{\|b\|}} \quad \text{e' ottenuto} \quad \text{ordine } \approx 10^{-16}$$

$$\|\delta x\| = \|A^{-1} \cdot \delta b\| \leq \|A^{-1}\| \cdot \|\delta b\| \leq \frac{\|\delta b\|}{\|b\|}$$

confronto tra errore imprecise relativo $\frac{\|\delta x\|}{\|x\|}$ e l'errore imprecise sul termine noto $\frac{\|\delta b\|}{\|b\|}$

Perturbazione delle sole matrice ($\delta b=0$)

$$Ax=b$$

$$(A+\Delta A)(x+\delta x) = b$$

$$Ax = (A+\Delta A)(x+\delta x) = A(x+\delta x) + \Delta A(x+\delta x) \rightarrow \delta x = A^{-1} \Delta A(x+\delta x)$$

$$\frac{\|\delta x\|}{\|x+\delta x\|} \leq \|A^{-1}\| \cdot \|A\| \cdot \frac{\|\Delta A\|}{\|A\|}$$

Perturbazione di matrice e termine noto

$$\frac{\|x-y\|}{\|x\|} \leq \underbrace{\|A^{-1}\| \cdot \|A\|}_{\text{errore relativo sia sui dati che sul termine noto}} \frac{1}{(1-\alpha)}$$


$$\text{legato all'errore sui dati } \delta > 0 \quad \frac{\|\Delta A\|}{\|A\|} \leq \delta \quad \frac{\|\delta b\|}{\|b\|} \leq \delta$$

NUO DI CONDIZIONE

$$\hookrightarrow K(A) = \|A\| \cdot \|A^{-1}\| \quad \rightarrow A \text{ deve essere quadrata e non singolare}$$

$$\frac{1}{K(A)} = \min_B \frac{\|A-B\|}{\|A\|}$$

distanza tra la matrice A e una matrice B singolare



distanza tra le 2 matrici

NB: quando $K(A)$ alto, A "imposta a componenti" come una matrice singolare

RISOLUZIONE SISTEMI LINEARI : METODI ITERATIVI

$Ax=b$ esistono successive di vettori $\{\vec{x}_1, \vec{x}_2, \dots\}$ tali che $x_n \xrightarrow{n \rightarrow \infty} x^*$ soluzione del sistema

Schema algoritmo iterativo:

1. Dati: x_0

2. $k=1$

3. Ripeti finché convergenza

3.1 $x_k = G(x_{k-1})$

3.2 $k = k + 1$


Cerco un K^* tale che $x_{k^*} \approx x^* \Rightarrow$ si genera un errore di truncamento

poiché un procedimento che dovrebbe avere infinito, viene troncato in passi finiti

errore truncamento = $\|x_{k^*} - x^*\|$

K viene solitamente definito $\leq \max_i t$ (numero di iterazioni massima)

Velocità di convergenza



apparentemente M_2 è più veloce. M_1 ha T_{M_1} come tempo per una singola iterazione. M_2 ha invece T_{M_2}

Il tempo totale è dato da:

$$\text{per } M_1 \rightarrow T_{\text{tot}} = T_{M_1} \cdot K_{M_1}$$

$$\text{per } M_2 \rightarrow T_{\text{tot}} = T_{M_2} \cdot K_{M_2}$$

Convergenza metodi iterativi: la successione x_K si dice convergente ad un vettore d con ordine $p \geq 1$ se

$$\exists C > 0 : \frac{\|x_{K+1} - d\|}{\|x_K - d\|^p} \leq C, \quad \forall K : K \geq K_0 \quad \left\{ \begin{array}{l} \text{dove } d = x^* \\ \|e_K\| \leq C \cdot \|e_{K-1}\| \end{array} \right. \quad \text{dove } \|e_K\| = \|x_K - d\|$$

Nel caso $p=1$, per avere convergenza $C \leq 1$. In questo caso C = fattore di convergenza

Tra i metodi, a parità di ordine p , è migliore quello con lo C più piccolo, altrimenti, se due metodi hanno p diverse, è migliore quello con lo p maggiore.

Nei metodi iterativi il costo iterazione è quasi sempre un $O(m^2)$ $\rightarrow T_{\text{tot}} = T_{i\tau} \cdot N_i \tau = O(m^2) \cdot N_i \tau$

Se si fanno m iterazioni \rightarrow ha un costo $O(m^3)$, mentre con fattorizzazioni LR $\rightarrow O(\frac{2}{3}m^3)$

NB i metodi iterativi si adattano bene alle matrici sparse (tanti elementi = 0)

$A \in \mathbb{R}^{m \times m}$ \rightarrow A ha m^2 elementi dei quali $m \ll m^2 \neq 0$

① Memoria di A solo gli m elementi e i loro indici (risparmio di memoria)

② $T_{i\tau} = O(m)$ $\rightarrow T_{\text{tot}} = O(m^2 \cdot m)$

INTRODUZIONE AI METODI ITERATIVI STAZIONARI

$A \in \mathbb{R}^{m \times m}$ matrice non singolare $\rightarrow A = M - N$

trapez superiore, trapez inferiore, diagonale ecc...
dove M è non singolare e $M^{-1}N$ facilmente risolvibile

$$Ax = b \rightarrow Mx - Nx = b \rightarrow \underbrace{M^{-1}Mx}_{I} - \underbrace{M^{-1}Nx}_{T} = \underbrace{M^{-1}b}_{C}$$

$$x = Tx + c$$

$$x_K = Tx_{K-1} + c \quad K = 1, 2, \dots$$

Dobbiamo dimostrare che converge alla soluzione

$$x_K \xrightarrow{K \rightarrow \infty} x^* \quad x_{K-1} \xrightarrow{K \rightarrow \infty} x^* \Rightarrow x^* = Tx^* + c$$

Un metodo è convergente se $\forall x_0$, la successione x_n converge

$$\text{es} \quad T = \begin{pmatrix} 1/2 & 0 & 0 \\ 0 & 1/2 & 0 \\ 0 & 0 & 2 \end{pmatrix} \quad c = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}$$

$$x_k = T \cdot x_0$$

$$\left\{ \begin{array}{l} x_{k+1} = Tx_k + c = 0 \\ x_1 = Tx_0 \rightarrow x_2 = Tx_1 = T(Tx_0) = T^2(x_0) \\ x_3 = T(x_2) = T(Tx_1) = T(T(Tx_0)) = T^3(x_0) \end{array} \right.$$

$x_k \xrightarrow{k \rightarrow \infty}$ converge?

$$T^k = \begin{pmatrix} 1/2^k & 0 & 0 \\ 0 & 1/2^k & 0 \\ 0 & 0 & 2^k \end{pmatrix} \quad k \rightarrow \infty$$

$$\text{Se } x_0 = (1, 0, 0) \rightarrow x_k = T^k \cdot x_0 = T^k \cdot \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} = \begin{pmatrix} 1/2^k \\ 0 \\ 0 \end{pmatrix}$$

$$\text{Se } x_0 = (0, 0, 1) \rightarrow x_k = T^k \cdot \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 2^k \end{pmatrix} \text{ diverge per } k \rightarrow \infty$$

TEOREMA: il metodo iterativo è convergente se e solo se $\rho(T) < 1$ → il più grande autovalore di T è nel cerchio

VELOCITÀ DI CONVERGENZA

Fissata una norma di vettori e le corrispondenti norme di matrici indotta, si ha

$$\text{errore al passo } k \quad \|e_k\| \leq \|T^k \cdot e_0\| \leq \|T^k\| \cdot \|e_0\| \quad \text{dove } e_k = \|x_k - x^*\| \text{ errore al passo } k$$

es

$$T = \begin{pmatrix} 0.5 & 0 \\ 0 & 0.6 \end{pmatrix} \quad S = \begin{pmatrix} 0.5 & 0.25 \\ 0 & 0.5 \end{pmatrix} \rightarrow T^k = \begin{pmatrix} 0.5^k & 0 \\ 0 & 0.6^k \end{pmatrix} \quad S^k = \begin{pmatrix} 0.5^k & 0.5^k \cdot 0.25^{k-1} \\ 0 & 0.5^k \end{pmatrix}$$

$$\text{uso } \|\cdot\|_\infty \quad \|T^k\|_\infty = 0.6^k \quad \|S^k\|_\infty = (2+k) 0.5^{k+1}$$

• per $k \leq 9$ ho $\|T^k\|_\infty < \|S^k\|_\infty$, mentre per $k \geq 10$ ho $\|T^k\|_\infty > \|S^k\|_\infty$


COSTRUTTORE DEI METODI ITERATIVI

$$A = D - E - F$$

dove $D = \{a_{11}, a_{22}, \dots, a_{mm}\}$ la diagonale di A

- E è la parte strettamente triangolare inferiore di A

- F è la parte strettamente triangolare superiore di A



METODO DI JACOBI (metodo delle sostituzioni simultanee)

$$M = D \quad \leftarrow \text{diagonale}$$

$N = E + F \rightarrow E$ strettamente triangolare inferiore, F strett triangolare superiore

matrice di iterazione

$$J = D^{-1}(E + F) = I - D^{-1}A$$

definito se D è non singolare (diagonale $\neq 0$)

$$x_{k+1} = J \cdot x_k + D^{-1}b$$

$$x_i^{(k)} = b_i - \left[\sum_{j=1}^{i-1} a_{ij} \cdot x_j^{(k-1)} - \sum_{j=i+1}^m a_{ij} \cdot x_j^{(k-1)} \right] / a_{ii}$$

Jx_k

componente i -esima al passo k

Metodo di GAUSS - SEIDEL

(metodo delle sostituzioni successive)

$$M = D - E$$

$$N = F$$

$$\text{matrice di iterazione } L_1 = (D - E)^{-1} F$$

definito se $D - E$ è non singolare

$$x_{k+1} = L_1 x_k + (D - E)^{-1} \cdot b$$

Criteri d'arresto

$$\|x_k - x_{k-1}\| \leq \epsilon \|x_k\|$$

dove ϵ è una quantità positiva prefissata

NOTA:

Gauss - Seidel, Jacobi convergono solo

se $\rho(A) < 1$ (caso speciale < 1). Più

$\rho(A)$ tende a 0 e più converge velocemente

Matrici particolari

- A è com diagonale dominante im senso stretto se

$$|a_{ii}| > \sum_{j \neq i} |a_{ij}| \quad \text{per ogni } i = 1, 2, \dots, m$$

- A è inniducibile se $\exists P$ di permutazione per cui

$$PAP^{-1} = \begin{pmatrix} B_{11} & B_{12} \\ 0 & B_{22} \end{pmatrix} \quad \text{con } B_{11}, B_{22} \text{ matrici quadrate}$$

- A è inniducibile com diagonale dominante se A è inniducibile e

$$|a_{ii}| \geq \sum_{j \neq i} |a_{ij}|, \quad i = 1, 2, \dots, m \quad \text{com domino un } i \text{ per cui vale im senso stretto}$$

JACOBI CONVERGENTE SE: A è com diagonale dominante im senso stretto o inniducibile com diagonale dominante

GAUSS - SEIDEL CONVERGENTE SE: A è com diagonale dominante im senso stretto o inniducibile com diagonale dominante

Sia A una matrice hermitiana (simmetrica) non singolare \Rightarrow Gauss Seidel converge se e solo se A è definita positiva

↓
tutti autovettori: $R \geq \lambda_i > 0 \quad \forall i$

Nelle matrici tridiagonali

$$A = \begin{pmatrix} a_1 & c_1 & & & \\ b_1 & a_2 & c_2 & & \\ & \ddots & \ddots & \ddots & \\ & & a_{n-1} & 2 & c_{n-1} \\ & & & b_{n-1} & a_n \end{pmatrix}$$

Se μ autoreale di $J \Rightarrow \mu^2$ autoreale di G

Se λ autoreale non nullo di G $\Rightarrow \sqrt{|\lambda|}$ autoreale di J

Quindi per queste matrici, Gauss - Seidel converge se e solo se Jacobi converge e vice

$$\rho(G) = \rho^2(J) \quad (\Rightarrow \rho(G) < \rho(J) \quad \text{perché entrambi} < 1)$$

immagine $\rho(J) = 0,4$

$$\rho(G) = \rho(J)^2 = 0,16$$

G & migliora

$$x_k = f(x_{k-1}) + (D-E)^{-1}b$$

Metodi di rilassamento

Gauss-Seidel può essere scritto come:

$$x_k = x_{k-1} + r_k \quad \text{dove } r_k = x_k - x_{k-1} = D^{-1}(Ex_k + Fx_{k-1} + b) - x_{k-1}$$

Quindi il punto x_k si ottiene a partire da x_{k-1} effettuando un passo nella direzione r_k di lunghezza $\|r_k\|_2$.

Non sempre ciò provoca una convergenza veloce. Si modifica la lunghezza del passo introducendo ω

$$x_k = x_{k-1} + \omega r_k$$

$$\begin{cases} \omega < 0 & \text{sottrassimento} \\ \omega > 0 & \text{sovrarassimento} \end{cases}$$

GAUSS-SEIDEL RILASSATO (SOR)

$$x_k = (D - \omega E)^{-1}((1-\omega)D + \omega F)x_{k-1} + \omega(D - \omega E)^{-1}b$$

$$\text{la cui matrice di iterazione } L_\omega = (D - \omega E)^{-1}((1-\omega)D + \omega F)$$

Una condizione necessaria di convergenza per SOR è:

$$0 < \omega < 2$$

Teorema (Ostrowski - Reich): Se A è definito positivo e $0 < \omega < 2 \Rightarrow$ il metodo di rilassamento è convergente

(IMPORTANTE)

FATTORIZZAZIONE DI CHOLESKY

sdp: simmetrica definita positiva

metodo olinette

Ogni matrice A sdp può essere fattorizzata come

$$A = L \cdot L^T \quad \text{con } L \text{ triang. inf non singolare e } L^T \text{ triang. sup non singolare}$$

Se A è sdp \Rightarrow tutte le sue sottomatrici sono sdp

non necessariamente diagonali di $L = 1 \dots 1$

Ad ogni passo j prende la sottomatrice $A_j = L_j \cdot L_j^T$

- passo 1 $A_1 = L_1 \cdot L_1^T \quad A_1 = a_{11} > 0$

$$L_1 \cdot L_1^T = a_{11} \quad \rightarrow \quad L_{11} = \sqrt{a_{11}}$$

- passo 2 $A_2 = L_2 \cdot L_2^T$

$$\begin{pmatrix} l_{11} & 0 \\ l_{21} & l_{22} \end{pmatrix} \cdot \begin{pmatrix} l_{11} & l_{21} \\ 0 & l_{22} \end{pmatrix} = \begin{pmatrix} l_{11}^2 & l_{11} \cdot l_{21} \\ l_{11} \cdot l_{21} & l_{22}^2 + l_{21}^2 \end{pmatrix} = \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix}$$

ricavo $l_{21} = \frac{a_{12}}{l_{11}}$

$l_{22} = \sqrt{a_{22} - l_{21}^2}$

sono noti

per induzione ceso $A_{K-1} = L_{K-1} \cdot L_{K-1}^T$

- al passo K conosco $A_{K-1} = L_{K-1} \cdot L_{K-1}^T$

$$A_K = \begin{pmatrix} A_{K-1} & a_{K \cdot K} \\ a_{K \cdot K}^T & a_{K \cdot K} \end{pmatrix}$$

NOMINAZIONE RARITATICA

ad esempio :

$$A_3 = \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{pmatrix} = \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{pmatrix}$$

a_{14}

vettore nullo di $K-1$ elementi

$$L_K = \begin{pmatrix} L_{K-1} & \vec{0} \\ L_{K-1}^T & \lambda \end{pmatrix}$$

$K-1$ colonne

$$A_K = L_K \cdot L_K^T$$

le complessità computazionale dell'algoritmo è $O(m^3/6)$ [la metà delle flessionazioni $LR \rightarrow O(\frac{m^3}{3})$]

l'algoritmo è stabile e non serve pivoting

$$A_K x = b \rightarrow L \cdot L^T x = b \rightarrow \begin{cases} Ly = b \\ y = L^T x \end{cases}$$

METODO GRADIENTI CONIGUATI (G.C) metodo iterativo { dove $x_{K+1} = x_K + d_K p_K$ con $d_K \in \mathbb{R}$, $p_K \in \mathbb{R}^n$ }

Vettore residuo : indice la "distanza" della soluzione corretta al passo K

$$r_K = b - A \cdot x_K \quad \text{se } x^* \text{ fosse la soluzione esatta} \Rightarrow A \cdot x^* = b \Rightarrow r_K = b - A \cdot x^* = \vec{0}$$

Teorema: Sei A simile allora l'algoritmo dei gradienti congiunti calcola la soluzione in m passi: $x_m = x^*$

ma lavorando con i numeri finiti le iterazioni sono maggiori di m

Calca l'iterazione K -esima come: $x_{K+1} = x_K + d_K p_K$ $d_K \in \mathbb{R}$ detto passo e p_K è una direzione di discesa

N.B. in aritmetica finita le iterazioni possono essere anche infinite

Le iterazioni si feriscono quando si raggiunge un criterio di convergenza

[ORDINE DI CONVERGENZA: $\exists c > 0, t.c. \|e_{K+1}\| \leq c \|e_K\|^p \leq \dots \leq c^{K+1} \|e_0\|^p$ adattabile ai metodi iterativi.]

Criterio di corretto: relazione di decrescita dell'errore in norma A

$$\|x_K - x^*\|_A \leq \gamma \|x_0 - x^*\|_A \left(\frac{K_2(A) - 1}{K_2(A) + 1} \right)^2$$

$$\|e_K\|_A \leq \gamma \|e_0\|_A \left(\frac{K_2(A) - 1}{K_2(A) + 1} \right)^2 \rightarrow c_1$$

In norma A : $\|x\|_A = x^T \cdot A \cdot x \geq 0$

norma energetica solo se A simmetrica definitiva

$$R(A) = \|A\| \cdot \|A^{-1}\| \geq 1 \quad \text{con } K_2(A) \text{ uscita minima } \Rightarrow K_2(A) = \|A\|_2 \cdot \|A^{-1}\|_2$$

Tanto più $K(A)$ è vicino ad 1, tanto più il motivo decresce velocemente

Criterio per terminare le iterazioni

$$\|b - Ax_K\|_2 = \|r_K\|_2 \leq \eta \|b\|_2 \quad \text{dove } \eta \text{ è un valore fissato } (\approx 10^{-6})$$

$$\text{Se } r_0 \neq \vec{0} \rightarrow \frac{\|r_K\|_2}{\|r_0\|_2} \leq \eta \quad \text{criterio relativo sul residuo cioè faccio } \frac{r_K}{r_0} \text{ supponendo } r_0 \neq 0$$

AUTOVALORI

Definizione: una matrice $A \in \mathbb{R}^{n \times n}$, $\lambda \in \mathbb{R}$, $x \in \mathbb{R}^n$, si definisce autovalore se

$$Ax = \lambda x$$

x è detto autovettore associato all'autovalore λ

Per calcolare gli autovalori, trovo gli zeri del polinomio caratteristico

$$p_A(\lambda) \Rightarrow \det(A - \lambda I) = 0 \quad \text{radici}$$

Se $\lambda \in \mathbb{C}$ è autovalore \Rightarrow è coniugato del
è autovalore $(\bar{a}+bi)$ coniugato $(\bar{a}-bi)$

Per avere autovettori di norma 1, li divido per la loro lunghezza

$$\omega = \frac{v}{\|v\|_2} \rightarrow \|w\|=1 \quad \text{normalizzato}$$

Calcolo autovettori:

METODO DELLE POTENZE

do spettro di una matrice $A \rightarrow$ insieme di tutti i suoi autovalori. I più importanti sono i maggiori in modulo

- * ipotesi: (1) $|\lambda_1| > |\lambda_2| > \dots > |\lambda_m|$ NB λ_1 distinto dagli altri
- (2) x_1, \dots, x_m lin indipendenti

Supponiamo di voler calcolare l'autovettore di valore massimo di A (λ_1). Denotiamo con x_1 l'autovettore associato a λ_1 tale che $\|x_1\|=1$. Se gli autovettori x_1, \dots, x_m sono indipendenti, posso calcolare λ_1 e x_1 con il metodo delle potenze.

IDEA: Definisco un vettore iniziale $x^{(0)} \in \mathbb{R}^n$ e posto $y^{(0)} = \frac{x^{(0)}}{\|x^{(0)}\|}$ (normalizzazione), si calcola per $k=1, 2, \dots$

$$x^{(k)} = A \cdot y^{(k-1)}, \quad y^{(k)} = \frac{x^{(k)}}{\|x^{(k)}\|}, \quad \lambda^{(k)} = (y^{(k)})^T A y^{(k)} \quad \text{scalare}$$

$$y^{(1)} = \frac{x^{(1)}}{\|x^{(1)}\|} \quad y^{(2)} = \frac{x^{(2)}}{\|x^{(2)}\|} = \frac{A \cdot y^{(1)}}{\|A \cdot y^{(1)}\|} = \frac{A \frac{x^{(1)}}{\|x^{(1)}\|}}{\|A \frac{x^{(1)}}{\|x^{(1)}\|}\|} = \frac{A \frac{A y^{(0)}}{\|A y^{(0)}\|}}{\|A \frac{A y^{(0)}}{\|A y^{(0)}\|}\|} = \frac{A^2 y^{(0)}}{\|A^2 y^{(0)}\|}$$

generalmente ho
necessario
 $y^{(k)} = \beta^{(k)} \circ \alpha^k \circ y^{(0)}$

$$\text{dove } \beta^{(k)} = \prod_{i=1}^k \left(\|x^{(i)}\|^{-1} \right)$$

Analisi di convergenza

Poiché x_1, \dots, x_m lin indipendenti, generano una base di \mathbb{R}^n . Di conseguenza, $x^{(0)}$ e $y^{(0)}$ possono essere scritti come combinazioni di x_1, \dots, x_m

$$x^{(0)} = \sum_{i=1}^m \alpha_i x_i, \quad y^{(0)} = \beta^{(0)} \cdot \sum_{i=1}^m \alpha_i x_i$$

$$x^{(1)} = A y^{(0)} = \beta^{(0)} \cdot A \cdot \sum_{i=1}^m \alpha_i x_i$$

A non dipende da i

\rightarrow lo punto nelle somme

$$= \beta^{(0)} \cdot \sum_{i=1}^m A x_i \alpha_i = \beta^{(0)} \cdot \sum_{i=1}^m \lambda_i x_i \alpha_i$$

$\lambda_1 = \lambda_k$ autovettore

$$y^{(k)} = \beta^{(k)} \cdot \sum_{i=1}^m d_i \cdot \lambda_i^{(k)} \cdot x_i$$

$$\beta^{(k)} = \frac{1}{\|x^{(1)}\| \dots \|x^{(m)}\|}$$

quindi $y^{(k)} = \lambda_1^{(k)} \cdot \beta^{(k)} \left(d_1 \cdot x_1 + \sum_{i=2}^m d_i \cdot \frac{\lambda_i^{(k)}}{\lambda_1^{(k)}} x_i \right)$

Poiché $|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_m| \Rightarrow \left(\frac{d_i}{\lambda_1}\right)^k < 1$ per $k \rightarrow \infty$ tende a zero

$y^{(k)}$ $\xrightarrow{k \rightarrow \infty} \lambda_1^{(k)} \beta^{(k)} d_1 x_1$ quindi $y^{(k)}$ tende ad essere associato ad uno degli autovettori di A

Gli errori e le velocità di convergenza sono proporzionali al rapporto $\left|\frac{\lambda_2}{\lambda_1}\right|^k$ ($\|x^{(k)}\| = c \|x^{(1)}\| \left(\frac{\lambda_2}{\lambda_1}\right)^{k-1} \leq c \left(\frac{\lambda_2}{\lambda_1}\right)^k$)

Tanto più c è piccolo, tanto più il metodo converge velocemente

METODO DELLE POTENZE INVERSE \rightarrow metodo delle potenze applicato alla matrice inversa

Se $\lambda_1, \dots, \lambda_m$ sono gli autovettori di A , allora $\frac{1}{\lambda_1}, \dots, \frac{1}{\lambda_m}$ sono gli autovettori di A^{-1}

Per approssimare l'autovettore minimo di A , approssimiamo il max di A^{-1} e poi faccio il reciproco

Dato $x^{(0)}$, $y^{(0)} = \frac{x^{(0)}}{\|x^{(0)}\|}$, per $k=1, 2, \dots$

sono uguali $x^{(k)} = A^{-1} \cdot y^{(k-1)}$, $y^{(k)} = \frac{x^{(k)}}{\|x^{(k)}\|}$, $\mu^{(k)} = (y^{(k)})^T A^{-1} \cdot y^{(k)}$

NB In tutte le iterazioni A non cambia. Posso sottoscrivere LR (LU) [o cholky se A simmetrico definita positiva] e ad ogni iterazione risolvere 2 problemi triangolari

Particolari agli autovettori

$$\|A\|_2 = \sqrt{\rho(A^T \cdot A)} = \sqrt{|\lambda_{\max}(A^T \cdot A)|}$$

① Se A è simmetrica $\rightarrow A^T \cdot A = A \cdot A = A^2$ prodotto matriciale

② Se λ_i è autovettore di A allora $\frac{1}{\lambda_i}$ è autovettore di A^{-1}

③ Se A è simmetrica $\rightarrow A^{-1}$ è simmetrica $\Rightarrow (A^{-1})^T \cdot (A^{-1}) = A^{-1} \cdot A^{-1} = (A^{-1})^2$

allora gli autovettori di $(A^{-1})^2 = \left(\frac{1}{\lambda_i}\right)^2$ con λ_i autovettore di A

④ A^2 ha autovettori $(\lambda_i)^2$

$$\sqrt{\lambda_2} \cdot \sqrt{\lambda_m}$$

NB: Se A è simmetrica $\rightarrow K_2(A) = \|A\|_2 \cdot \|A^{-1}\|_2 = \sqrt{\lambda_{\max}(A^T \cdot A)} \cdot \sqrt{\lambda_{\max}(A^{-1})^T \cdot (A^{-1})} = \sqrt{\lambda_1^2} \cdot \sqrt{\frac{1}{\lambda_m^2}} =$

continua $\sqrt{\frac{\lambda_1^2}{\lambda_m^2}} = \sqrt{\left(\frac{\lambda_1}{\lambda_m}\right)^2} = \left|\frac{\lambda_1}{\lambda_m}\right| \geq 1$

Se λ_1 è il max autovettore di A $\Rightarrow \frac{1}{\lambda_m}$ è il max autovettore di A^{-1}

maggiorazione è $\left|\frac{\lambda_1}{\lambda_m}\right|$ e più la matrice è mal condizionata

Se A è sdp $\Rightarrow K_2(A) = \frac{\lambda_1}{\lambda_m}$ (autovettori tetti, > 0)

$\lambda_1 > \lambda_2 \geq \dots \geq \lambda_m \rightarrow \frac{1}{\lambda_1} \leq \dots \leq \frac{1}{\lambda_{m-1}} < \frac{1}{\lambda_m}$

INTERPOLAZIONE

coppie (x_i, y_i) $i=0, \dots, m$

$$y_i = f(x_i)$$

obiettivo: trovare una funzione che descrive l'andamento dei dati

Possiamo avere due tipi:

- ① Interpolazione \rightarrow la funzione passa per i punti (se i dati non sono affetti da errori e sono pochi)
- ② Approssimazione \rightarrow la funzione passa vicino ai punti

3 tipi di interpolazione: conosciamo $m+1$ valori $\{x_i, y_i\}$ $i=0, \dots, m$ con gli x_i distinti tra loro (noi)

① POLINOMIALE: $\tilde{f} = a_0 + a_1 x + a_2 x^2 + \dots + a_m x^m$

② TRIGONOMETRICA

③ RAZIONALE

Interpolazione polinomiale di Lagrange

Per ogni coppia $\{x_i, y_i\}$ $i=0, \dots, m$ con x_i distinti tra loro, esiste un unico polinomio di grado $\leq m$ (indicato con T_m)

chiamato polinomio interpolatore tale che

$\{T_m \text{ è il polinomio}\}$

$$T_m(x_i) = y_i \quad i=0, \dots, m$$

Se $y_i = f(x_i) \Rightarrow T_m$ è l'interpolazione di f e si intuisce con T_m^f

- T_m è unico:

Per assurdo, esiste T_m^* polinomio interpolatore $\Rightarrow T_m - T_m^*$ è un polinomio, ma $(T_m - T_m^*)(x_i) = 0$

quindi si annulla in $m+1$ punti \Rightarrow ha $m+1$ radici \Rightarrow grado $m+1$ ed è un assurdo \Rightarrow i polinomi sono uguali

- T_m esiste sempre:

$$T_m = a_0 + a_1 x + a_2 x^2 + \dots + a_m x^m$$

$$i=0 \Rightarrow a_0 + a_1 x_0 + \dots + a_m x_0^m = y_0$$

\vdots

$$i=m \Rightarrow a_0 + a_1 x_m + \dots + a_m x_m^m = y_m$$

$\left. \begin{array}{l} \text{le incognite sono } a_0, \dots, a_m \\ \text{e} \end{array} \right\} \Rightarrow$

ho $m+1$ equazioni ed $m+1$ incognite \Rightarrow ho solo 1 soluzione

$$\vec{a} = \begin{pmatrix} a_0 \\ \vdots \\ a_m \end{pmatrix} \quad \vec{y} = \begin{pmatrix} y_0 \\ \vdots \\ y_m \end{pmatrix} \quad X = \begin{pmatrix} 1 & x_0 & x_0^2 & \dots & x_0^m \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_m & x_m^2 & \dots & x_m^m \end{pmatrix}$$

X si chiama matrice di Vandermonde ed è molto condizionata $\Rightarrow X \cdot \vec{a} = \vec{y}$ non si può calcolare

Per calcolare le incognite a_0, \dots, a_m possiamo usare l'algoritmo di Lagrange



APPROXIMAZIONE
INTERPOLAZIONE

DEF spazio funzionale: spazio vettoriale formato da funzioni. Ha una base di funzioni ottenuta se si puo esprimere tutte le funzioni come combinazione delle funzioni della base

base monomiale: $\begin{cases} \varphi_0(x) = 1 \\ \varphi_1(x) = x \\ \vdots \\ \varphi_m(x) = x^m \end{cases}$ $\rightarrow m+1$ elementi

φ_k corrisponde ad x^k nella base monomiale (una i monomi)

$$P_m(x) = c_0 \varphi_0(x) + c_1 \cdot \varphi_1(x) + \dots + c_m \varphi_m(x)$$

cambiando la base cambiano i componenti

NB Nella base di Lagrange, le φ non sono piu i monomi e i coefficienti ci sono le coordinate dei dati

$$c_0 = y_0, c_1 = y_1, \dots, c_m = y_m$$

Il polinomio nelle forme di Lagrange sare

$$P_m(x) = y_0 \varphi_0(x) + y_1 \varphi_1(x) + \dots + y_m \varphi_m(x) \quad \Rightarrow \varphi_k = L_k$$

La base di Lagrange è $\{L_0, L_1, \dots, L_m\}$ $\rightarrow P_m(x) = y_0 \cdot L_0(x) + y_1 L_1(x) + \dots + y_m L_m(x)$

- $L_k(x) = \varphi_k(x) = \prod_{\substack{j=0 \\ j \neq k}}^m \frac{x - x_j}{x_k - x_j} \quad k=0, \dots, m$ prodotto per $j=0 \dots m$ con $j \neq k$

$$L_0(x) = \varphi_0(x) = \left(\frac{x - x_0}{x_1 - x_0} \right) \cdot \left(\frac{x - x_2}{x_1 - x_2} \right) \cdot \dots \cdot \left(\frac{x - x_m}{x_1 - x_m} \right) \quad \text{e Bas di Lagrange di ordine } 1$$

$$L_1(x) = \varphi_1(x) = \left(\frac{x - x_0}{x_2 - x_0} \right) \cdot \left(\frac{x - x_1}{x_2 - x_1} \right) \cdot \left(\frac{x - x_3}{x_2 - x_3} \right) \cdot \dots \cdot \left(\frac{x - x_m}{x_2 - x_m} \right) \quad \text{e indice 2}$$

Calcolo L_1 in x_1 :

$$L_1(x_1) = \left(\frac{x_1 - x_0}{x_1 - x_0} \right) \cdot \left(\frac{x_1 - x_2}{x_1 - x_2} \right) \cdot \dots \cdot \left(\frac{x_1 - x_m}{x_1 - x_m} \right) = 1$$

Calcolo L_1 in x_2 :

$$L_1(x_2) = \left(\frac{x_2 - x_0}{x_2 - x_0} \right) \cdot \left(\frac{x_2 - x_1}{x_2 - x_1} \right) \cdot \dots = 0$$

NB se calcolo $L_i(x_i) = 1$, invece $L_i(x_j) = 0 \forall j \neq i$

Il polinomio $P_m(x_i) = y_i$ per $i=0, \dots, m$

$$P_m(x_0) = c_0 \underbrace{\varphi_0(x_0)}_{=1} + c_1 \underbrace{\varphi_1(x_1)}_{=0} + \dots + c_m \underbrace{\varphi_m(x_m)}_{=0} = y_0 \rightarrow c_0 \underbrace{\varphi_0(x_0)}_{=1} = y_0 \rightarrow c_0 = y_0$$

Il polinomio di interpolazione nelle formule di Lagrange è quindi

$$P_m(x) = \sum_{k=0}^m y_k \cdot \varphi_k(x)$$

Interpolazione di una funzione $(x_{ik}, y_{ik}) = (x_k, f(x_k))$

Voglio vedere l'errore commesso nei punti

Nei punti di interpolazione $|f(x_i) - \Pi_m(x_i)| = 0$, mentre negli altri punti

$$E_m f(x) = f(x) - \Pi_m f(x) = \frac{f^{(m+1)}(\xi)}{(m+1)!} \prod_{i=0}^m (x - x_i)$$

Se $m \rightarrow \infty$, cioè avremo i punti di interpolazione allo stesso numero


$$\lim_{m \rightarrow \infty} \max_{x \in I} |E_m f(x)| = \infty$$

Usando i punti di Chebyshev nell'intervalle (a, b) \rightarrow l'errore commesso nei punti tende a zero

$$x_0 = a, x_m = b, x_i = \frac{a+b}{2} - \frac{b-a}{2} \cdot \cos\left(\frac{2i+1}{m+1} \cdot \frac{\pi}{2}\right) \quad (i=0, \dots, m)$$


i punti sono più densi nei bordi dell'intervalle e meno densi al centro (sono simmetrici)

INTERPOLAZIONE POLINOMIALE A TRATTI



$x_i, i=0 \dots m$ equidistanti
 $y_i, i=0 \dots m$ misure

interpoliamo ogni sottointervalllo con un polinomio di grado p ($p=1, 2, 3$ solitamente)



p = grado $\rightarrow p=2$: parabola. \rightarrow ogni sottointervalllo $[x_i, x_{i+2}]$ è una parabola

APPROXIMAZIONE

Voglio trovare una funzione che approssima il fenomeno di cui riceviamo i dati, e che non forse misuriammo nei punti

I punti (x_i, y_i) potrebbero essere affetti da errori.

Ho m punti e voglio calcolare una funzione (polinomio) di grado m (ma è possibile)

in blu è la distanza tra punto e approssimazione $r_i = |P(x_i) - y_i|$



il vettore residui $r = (r_0, \dots, r_m) \rightarrow \|r\|_2$ è la distanza tra polinomio e punti, cerco di minimizzarla

(per semplicità calcolare $\min(\|r\|_2^2)$)

L'idea distanza tra il polinomio e i punti dove crea piccole

PROBLEMA AI MINIMI QUADRATI sta nel determinare il vettore $x \in \mathbb{R}^m$ che minimizza il vettore residui

$$r = Ax - b$$

$$\min_{x \in \mathbb{R}^m} (\|Ax - b\|_2)^2 = \min_{x \in \mathbb{R}^m} (\|r\|_2)^2$$

$$\hookrightarrow r = (r_0, r_1, \dots, r_m) = ((Ax)_0 - b_0, \dots, (Ax)_m - b_m) \quad \text{Calcol. } Ax \text{ e prendi le componenti } 0, 1, \dots, m$$

Condizione di esistenza e unicità dei minimi quadrati

Date $A \in \mathbb{R}^{m \times n}$ con $m > n$, $b \in \mathbb{R}^m$, $x \in \mathbb{R}^n$

Sia $K = \text{rg}(A) \leq m \Rightarrow$ il problema dei minimi quadrati ammette almeno 1 soluzione sempre

$K = m$ \rightarrow rango massimo: una sola soluzione unica

$K < m$ \rightarrow soluzioni infinite che creano un sottospazio di \mathbb{R}^m di dimensione $m-K$

(1) Caso $K=N$

A ha rango max $\rightarrow A$ è simmetrica e definita positiva

$$\begin{aligned} \|Ax - b\|_2^2 &= (Ax - b)^T(Ax - b) \\ &= (-b^T + x^T A^T)(Ax - b) \\ &= -b^T Ax + b^T b + x^T A^T Ax - x^T A^T b \\ (\text{sommendo i termini simili } b^T Ax = x^T A^T b) \\ &= x^T A^T Ax - 2x^T Ab + b^T b \end{aligned}$$

Si pone:

$$f(x) = x^T A^T Ax - 2x^T Ab + b^T b$$

$$\nabla f(x) = 2 \cdot A^T \cdot A \cdot x - A^T \cdot b$$

ponendo $\nabla f(x) = 0$ (cerco punti di flesso) $\rightarrow A^T \cdot A \cdot x = A^T \cdot b$

dove $A^T \cdot A$ è sdip $\rightarrow A$ ha rango massimo

$$\left\{ \begin{array}{l} L y = A^T \cdot b \\ y = L^T \cdot x \end{array} \right.$$

com L fattorizzato con Cholesky

$$K(A^T \cdot A) = K(A^2)$$

(2) Caso $K \leq N$

: decomposizione in valori singolari (SVD)

Tra le infinite soluzioni vogliamo quelle di minima norma

Sia $A \in \mathbb{R}^{m \times m}$, $m \geq n$, $K = \text{rg}(A) \leq n$ ALLORA ESISTONO:

- $U \in \mathbb{R}^{m \times m}$ ortogonale quadrata
- $V \in \mathbb{R}^{m \times m}$ ortogonale quadrata
- $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_m)$ con $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_n \geq 0$ detti valori singolari

$$\sum \epsilon \in \mathbb{R}^{m \times m} : \begin{pmatrix} \sigma_1 & & & \\ & \ddots & & \\ & & \sigma_m & \\ & 0 & \dots & 0 \end{pmatrix}$$

tutti zero nelle $m-n$ righe

$$\text{ALLORA: } A = U \cdot \Sigma \cdot V^T$$

NB: matrice ortogonale: $A \in \mathbb{R}^{m \times m}$ è ortogonale se, dette a_1, \dots, a_m le colonne di A , si ha che

$$\langle a_i, a_j \rangle = 0 \quad \forall i \neq j \quad \& \quad \|a_i\|_2 = 1$$

Una matrice ortogonale ha alcune proprietà:

$$\textcircled{1} A^T = A^{-1}$$

$$A \cdot A^{-1} = A \cdot A^T = I$$

$$\textcircled{2} \quad \forall v \in \mathbb{R}^m, \quad \|v\|_2 = \|A \cdot v\|_2$$

proprietà di isometria

prendo un vettore $v \in \mathbb{R}^m$, lo moltiplico per A ortogonale ottengo un vettore lungo uguale (non stessa dir??)

$$\textcircled{3} \quad A^T \text{ è ortogonale}$$

Teorema: Sia $A \in \mathbb{R}^{m \times m}$, $\text{rg}(A) = K \leq m$, sia $A = U \cdot \Sigma \cdot V^T$ la sua decomposizione in valori singolari, allora il vettore

$$x^* = \sum_{i=1}^K \frac{u_i^T \cdot b}{\sigma_i} \cdot v_i \quad \begin{array}{l} v_i \text{ è la colonna } i-\text{esima di } V \\ \text{dove } u_i^T \text{ è la colonna } i-\text{esima di } U, \text{ trasposta}, \sigma_i \in \mathbb{R} \end{array}$$

è la soluzione di minima norma del problema

$$\min_{x \in \mathbb{R}^m} (||Ax - b||_2)^2$$

$$\text{in corrispondenza otengo: } (\|r\|_2)^2 = (\|A x^* - b\|_2)^2 = \sum_{i=K+1}^m (u_i^T \cdot b)^2$$

DIM posso fare perché la minima norma uguale per l'isometria di U

$$\|A x - b\|_2^2 = (\text{moltiplico per } U^T) = \|U^T A x - U^T b\|_2^2 = \|U^T A \cdot V \cdot V^T x - U^T b\|_2^2$$

$$\text{posto } y = V^T \cdot x \in \mathbb{R}^m, \quad g = U^T \cdot b \in \mathbb{R}^m$$

$$\hookrightarrow V \text{ ortogonale} \Rightarrow V^T = V^{-1} \Rightarrow V \cdot V^T = V \cdot V^{-1} = I$$

Se $A = U \cdot \Sigma \cdot V^T \Rightarrow$ per ortogonalità di $U, V \Rightarrow U^T \cdot A \cdot V = \Sigma$. allora

$$\|A x - b\|_2^2 = \|\Sigma y - g\|_2^2$$

$$= \sum_{i=1}^K (\sigma_i y_i - g_i)^2 + \sum_{i=K+1}^m (g_i)^2$$

NB i valori singolari di A : $\sigma_1, \dots, \sigma_m > 0$, sono positivi in ordine decrescente e sono ≥ 0 finché $\sigma_k = 0$

$$\sigma_1, \dots, \sigma_n > 0 \quad \sigma_{n+1}, \dots, \sigma_m = 0 \quad \Sigma = \begin{pmatrix} \sigma_1 & & & \\ & \sigma_2 & & \\ & & \ddots & \\ & & & \sigma_m \\ 0 & \dots & & 0 \\ & & & 0 \end{pmatrix}_{m \times m} \begin{pmatrix} y_1 \\ \vdots \\ y_m \end{pmatrix}_{m \times 1} = \begin{pmatrix} x \\ \vdots \\ x \\ 0 \\ \vdots \\ 0 \end{pmatrix}_{m \times 1}^K \text{ elementi} \neq 0 \\ \text{non dipende da } x$$

Devo minimizzare rispetto ad x

$$\sum_{i=1}^k (\sigma_i y_i - g_i)^2 + \sum_{i=k+1}^m (g_i)^2$$

perché $= 0$

è una somma di quadrati $\rightarrow \text{primo} = 0$

$$\Rightarrow \sigma_i \cdot y_i = g_i \rightarrow y_i = \frac{g_i}{\sigma_i} = \frac{U^T b}{\sigma_i}$$

$$y_i = \frac{U^T b}{\sigma_i}$$

$$\text{poiché } y = V^T x \rightarrow V y = V \cdot V^T \cdot x \rightarrow x = V y$$

$$\text{ottenendo così } x^* = \frac{V \cdot U^T \cdot b}{\sigma_i} \iff x^* = \sum_{i=1}^k \frac{U^T b}{\sigma_i} \cdot v_i \text{ con } x^* \in \mathbb{R}^m$$

la norma del residuo, in corrispondenza di tale soluzione, è

$$\|r\|_2^2 = \sum_{i=k+1}^m (g_i)^2 = \sum_{i=k+1}^m (U^T b)^2$$

$$(x_i, y_i) \quad i=0, \dots, m \quad f_m(x) = a_0 + a_1 x + a_2 x^2 + \dots + a_m x^m \quad m \gg m \quad \left\{ \begin{array}{l} m+1 \text{ punti} \\ m+1 \text{ coefficienti} \end{array} \right.$$

$$r_i = f_m(x_i) - y_i = a_0 + a_1 x_i + a_2 x_i^2 + \dots + a_m x_i^m - y_i \quad (i=0, \dots, m)$$

Scritto in forma matriciale ottengo

$$\vec{r} = X \vec{a} - \vec{y} \quad \text{dove } \vec{a} = (a_0, \dots, a_m)^T \in \mathbb{R}^{m+1} \quad \text{incognita}$$

$$\vec{y} = (y_0, \dots, y_m)^T \in \mathbb{R}^{m+1}$$

$$X = \begin{pmatrix} 1 & x_0 & x_0^2 & \dots & x_0^m \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_m & x_m^2 & & x_m^m \end{pmatrix} \quad \text{rettangolare con } m+1 \text{ righe e } m+1 \text{ colonne}$$

"matrice di Vandermonde rettangolare"

$$\rightarrow \min \|r\|_2^2 = \min_{\vec{a} \in \mathbb{R}^{m+1}} \|X \vec{a} - \vec{y}\|_2^2 \quad \text{la minimizzazione rispetto ad } \vec{a} \text{ in } \mathbb{R}^{m+1}$$

$$\text{Cambio} \quad Ax = b \longrightarrow X \vec{a} = \vec{y}$$

$$\left\{ \begin{array}{l} A \longrightarrow X \\ \vec{x} \longrightarrow \vec{a} \\ \vec{b} \longrightarrow \vec{y} \end{array} \right.$$

Gomodilominimento del problema dei minimi quadrati

I valori singolari σ_i sono > 0 fino a σ_k con $K = \text{rg}(A)$, inoltre $A v_i = \sigma_i u_i$

c'è una relazione tra i valori singolari di A e gli autovettori di $A^T A$

vettori singolari desti

vettori singolari desti

vettori singolari sinistri

Ricordiamo $(xy)^T = y^T x^T$

$$A = U \cdot \Sigma \cdot V^T$$

I per ortogonalità

$$\text{NB } (xy)^T = y^T x^T$$

$$A^T A = (U \Sigma V^T)^T (U \Sigma V^T) = V \Sigma^T U^T U \Sigma V^T = V \Sigma^T \Sigma V^T$$

$(m \times m) \cdot (m \times m) \rightarrow (m \times m)$

NB $\Sigma^T \Sigma$ è una matrice $m \times m$ diagonale, con i valori singolari del prodotto sulle diagonali

$$A^T A = V \Sigma^T \Sigma V^T = V \cdot \begin{bmatrix} \sigma_1^2 & & \\ & \ddots & \\ & & \sigma_m^2 \end{bmatrix} \cdot V^T$$

V è la matrice degli autovettori
di $A^T A$

$$\text{In generale } \sigma_i = \sqrt{\lambda_i(A^T A)} \quad i=1 \dots m \quad \rightarrow (\sigma_i)^2 = \lambda_i(A^T A) \quad \text{autovettore } i\text{-esimo}$$

In particolare, se $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_m$

$$\bullet \quad \sigma_1 = \sqrt{\lambda_{\max}(A^T A)} = \sqrt{\rho(A^T A)} = \|A\|_2 \quad \text{Norma-2 di } A$$

$$\bullet \quad \sigma_m = \sqrt{\lambda_{\min}(A^T A)}$$

$$\hookrightarrow \text{di conseguente } \frac{1}{\sigma_m} = \|A^{-1}\|_2$$

$$K_2(A) = \|A\|_2 \cdot \|A^{-1}\|_2 = \frac{\sigma_1}{\sigma_m} \quad \text{condizionamento delle matrice } A$$

Approssimazione di una matrice tramite SVD \rightarrow estrarre il contenuto informativo di una matrice

Dato $A \in \mathbb{R}^{m \times m}$, $K = \text{rg}(A)$, $A = U \Sigma V^T$.

$$\text{Sia } A_p = \sum_{i=1}^p \sigma_i v_i u_i^T \quad \begin{cases} v_i = m \times 1 \\ u_i^T = 1 \times m \\ \sigma_i = \text{scala} \end{cases} \rightarrow \text{scala} \cdot \text{matrice } m \times m$$

A_p sono matrici di rango 1 (DIADE: matrice di rango 1)

$$\bullet \quad \text{Se } p=k \text{ allora } \sum_{i=1}^k \sigma_i v_i u_i^T = A$$

$\bullet \quad \text{Se } p < K \quad A_p$ è l'approssimazione di rango p di A ($\text{rg}(A_p) = p$)

$$\forall B \in \mathbb{R}^{m \times m}, \text{rg}(B) = p, \quad \|A - A_p\|_2 \leq \|A - B\|_2$$

\hookrightarrow Tra tutte le matrici di rango p , A_p è l'approssimazione migliore di A

A può essere scritto così $\sum_{i=1}^k \sigma_i v_i \cdot u^\top$, mentre $A_p = \sum_{i=1}^p \sigma_i v_i \cdot u^\top$
di conseguente $A - A_p = \sum_{i=p+1}^k \sigma_i v_i \cdot u^\top$

$\|A - A_p\|_2 = \sigma_{p+1}$ se σ_{p+1} è piccolo, si ha una buona approssimazione di A
questo numero è il valore singolare minimo. La distanza è il primo valore singolare da "tavolo"

RISOLVERE FUNZIONI NON LINEARI

$f: I \subset \mathbb{R} \rightarrow \mathbb{R}$, vogliamo calcolare gli zeri di f , cioè $f(x) = 0$

Weierstrass: Se f è continua in $[a, b]$, con $f(a) \cdot f(b) < 0$ allora f almeno una zero di f in (a, b)

METODI ITERATIVI

$x_k = G(x_{k-1})$, questi iterati convergono a x^* $\left[x_k \xrightarrow{k \rightarrow \infty} x^* \right]$ tale che $f(x^*) = 0$

x_k converge a x^* con un ordine $p \geq 1$ se $\frac{|x_{k+1} - x^*|}{|x_k - x^*|^p} = c$ $\forall k \geq k_0$

dove k_0 è un intero, $c \in \mathbb{R}$ tale che $\begin{cases} 0 < c \leq 1 & \text{se } p = 1 \\ c > 0 & \text{se } p > 1 \end{cases}$

Metodo di bisezione:

Porto un intervallo (a, b) tale che $f(a) \cdot f(b) < 0$ $\left[f(a) < 0, f(b) > 0 \right]$

costruisco $I_1 = [a, b]$, $I_2 = [a_2, b_2]$, ..., $I_k = [a_k, b_k]$

tali che $x^* \in I_k \quad \forall k \quad I_k \subseteq I_{k+1} \subseteq \dots \subseteq I_1$ con $f(a_k) \cdot f(b_k) < 0$

$$\text{calcolo} \quad c_k = \frac{a_k + b_k}{2}$$

se $f(c_k) = 0$ allora $x^* = c_k$

altrimenti $[a_{k+1}, b_{k+1}] = \begin{cases} [a_k, c_k] & \text{se } f(c_k) > 0 \\ [c_k, b_k] & \text{se } f(c_k) < 0 \end{cases}$

OSSERVAZIONI:

① $c = \frac{a+b}{2}$ per evitare che c sia fuori dall'intervallo $[a_k, b_k]$


② $|b_k - a_k| < \epsilon + \text{eps} \cdot \max(|b|, |a|)$ dove eps è la precisione macchina (per evitare under/overflow)

Iterando, mi ferma se $\Delta_k = |b_k - a_k|$ (lunghezza intervallo) $\rightarrow \Delta_k < \epsilon$

$$\tilde{x} \approx c_{k+1} = \frac{b_k + a_k}{2}$$

punto medio dell'intervallo $\rightarrow \|x^* - \tilde{x}\| \leq \frac{\epsilon}{2}$

$$\|x^* - \tilde{x}\| \leq \frac{\epsilon}{2}$$



Al passo k :

$$b_{k+1} - a_{k+1} = \frac{1}{2}(b_k - a_k) = \frac{1}{2}(b_{k-1} - a_{k-1}) = \dots = \frac{1}{2^k}(b - a)$$

quindi $x^* = c_{k+1} \pm \epsilon_{k+1}$, dove

$$\epsilon_{k+1} \leq \frac{b-a}{2^{k+1}}$$

tolleranza

l'ordine di convergenza rappresenta quanto diminuisce l'errore $|e_{k+1}| < C |e_k|^p$

in questo caso $p=1$, $C=\frac{1}{2}$ \Rightarrow il metodo è lento, di ordine convergente lineare

Metodo delle approssimazioni successive

Cercare $f(x)=0$, è comune di cercare $g(x)=x$, cioè un punto fisso della funzione g , definita

$$g(x) = x - f(x) \cdot \phi(x)$$

dove $\phi(x)$ è limitata e $\neq 0$ $0 < |\phi(x)| < \infty$ $x \in [a, b]$

quindi risolvere $f(x)=0$ equivale a risolvere $g(x)=x$

$$f(x)=0 \Leftrightarrow g(x)=x$$

$$\Rightarrow f(x^*)=0 \Rightarrow g(x^*) = x^* - \underbrace{f(x^*)}_{=0} \cdot \underbrace{\phi(x^*)}_{\neq 0} = x^*$$

$$\leftarrow g(x^*) = x^* \Rightarrow f(x^*)=0$$

$$\underbrace{x^* - f(x^*) \cdot \phi(x^*)}_{=x^*} = x^* \Rightarrow f(x^*) \cdot \underbrace{\phi(x^*)}_{\neq 0} = 0 \quad \text{allora} \quad f(x^*)=0$$

Il punto fisso della funzione $g(x)$ è geometricamente l'intersezione delle curve

$$y=x \quad y=g(x)$$

DEF: Convergenza globale = il metodo converge a $x^* \forall x_0$

intorno centato in x^* di raggio r

Convergenza locale = il metodo converge a x^* solo per un $x_0 \in I_p$ dove $I_p = [x^* - p, x^* + p]$

Teorema di esistenza e unicità del punto fisso nel modello continuo $(g(x)=x-f(x) \cdot \phi(x)$ ha il punto fisso?)

Sia $g(x)$ continua in $[a, b]$, tale che $g(x) \in [a, b]$. Sia L una costante $0 \leq L < 1$ tale che $\forall x, y \in [a, b]$

$$|g(x) - g(y)| \leq L|x-y|$$

essia g è una contrazione in $[a, b]$. Allora esiste un unico punto fisso x^* di $g(x)$ in $[a, b]$

NB occorre che g sia continua, $g(x) \in [a, b]$, g non oscilla troppo

Dato un'approssimazione iniziale x_0 di x^* , calcolo con una successione di iterati:

$$x_{k+1} = g(x_k)$$

convergenza del metodo del teorema delle funzioni

Se $g(x)$ è continua e la successione $\{x_k\}$ converge per $K \rightarrow \infty$ ad un punto x^* allora x^* è punto fisso di $g(x)$

$$x^* = \lim_{K \rightarrow \infty} x_{K+1} = \lim_{K \rightarrow \infty} g(x_K) = g \left(\lim_{K \rightarrow \infty} x_K \right) = g(x^*)$$

TEOREMA DI CONVERGENZA GLOBALE del metodo delle approssimazioni successive

quando la successione $\{x_0, \dots, x_K\}$ è convergente??

Sia $g(x)$ una funzione definita in $[a, b]$. Sia $g(x)$ continua in $[a, b]$, $g(x) \in [a, b]$, $g(x)$ contrazione in $[a, b]$

Allora $\forall x_0 \in [a, b]$, la successione degli iterati $x_K = g(x_{K-1})$ converge per $K \rightarrow \infty$ all'unico punto fisso x^* di $g(x)$

TEOREMA DI CONVERGENZA LOCALE

Sia x^* punto fisso di $g(x)$; sia $g(x)$ continua e contrazione in $[a, b]$ $\forall x \in [x^* - \rho, x^* + \rho] = I_\rho$

Allora $\forall x_0 \in I_\rho$, la successione degli $\{x_K\} \in I_\rho$ e converge per $K \rightarrow \infty$ all'unico punto fisso x^* di $g(x)$

la condizione $g(x) \in [a, b]$ non è necessaria nella convergenza locale

CITERI DI ARRESTO

x_K si ritiene approssimazione accettabile se verifica:

$$\boxed{|f(x_K)| \leq \epsilon_1} \quad \text{e} \quad |x_K - x_{K-1}| \leq \epsilon_2$$

$\Rightarrow |g(x_K) - x_K|$

oppure se

$$\frac{|f(x_K)|}{f_{\max}} \leq \delta_1 \quad \text{e} \quad \frac{|x_K - x_{K-1}|}{|x_K|} \leq \delta_2$$

dove $f_{\max} = \max_{x \in I_\rho} |f(x)|$



Se f è "piatta", la stessa condizione

$|f(x_K)| \leq \epsilon_1$ indurerrebbe

un intervallo troppo grande

Metodo di Newton

particolare metodo di punto fisso


Un metodo iterativo, ha velocità di convergenza lineare se poniamo $\phi(x) = \frac{x}{f'(x)}$ con $f'(x) \neq 0$

Se invece poniamo $\phi(x^*) = \frac{1}{f'(x^*)}$ con $f'(x^*) \neq 0$, allora la velocità di convergenza è quadratica

$$g(x) = x - \frac{f(x)}{f'(x)}$$

$$x_{K+1} = g(x_K) = x_K - \frac{f(x_K)}{f'(x_K)}$$

Il metodo di Newton è detto anche metodo delle tangenti perché geometricamente x_{K+1} è il punto di intersezione tra l'orme delle x ($y=0$) e la retta tangente a $f(x)$ in $(x_K, f(x_K))$



x_* è l'intersezione tra l'asse delle x , e $f'(x_*)$ (lim rosso)
dello stesso modo, x_2 è l'intersezione tra $\begin{cases} y=0 \\ y=f'(x_1) \end{cases}$ (lim blu)

SVANTAGGI

- costo computazionale più alto (devo calcolare derivate prima)
- dà errori derivate prime ≠ 0 A punto

Metodo di Newton non applicabile a tutte le f

Convergenza locale metodo di Newton

(rispetto al precedente (espresso per g), questo lo espriamo per proprietà di f)
Sia x^* uno zero di $f(x)$. Sia f continua insieme alle sue derivate prima, seconda e terza

Sia $f'(x) \neq 0$ per $x \in I_p$ (dove $I_p = [x^* - \rho, x^* + \rho]$), e sia $f''(x^*) \neq 0$

Allora $\forall x_0 \in I_p$ la successione generata converge a x^* in modo quadrattico

Convergenza globale del metodo di Newton

Sia $f \in C^2$ in $[a, b]$. Sia inoltre:

- $f(a) < 0 \quad f(b) > 0$
- $f'(x) \neq 0$
- $f''(x) \leq 0$
- $|f(b)| \leq (b-a)|f'(b)|$



Allora il metodo di Newton genera una successione di iterati convergenti all'unica soluzione di $f(x) = 0$ appartenente ad $[a, b]$ a partire da qualunque $x_0 \in [a, b]$

INTRODUZIONE PUNTI DI MINIMO

$f: \mathbb{R}^m \rightarrow \mathbb{R} \rightarrow \nabla f(x)=0$ NON PER FORZA X PUNTO DI MINIMO

- Se $x^* \in \mathbb{R}^m$ è di minimo se $f \in C^1$ (esistono tutte le m derivate prime parziali e sono continue). Allora $\nabla f(x^*) = 0$

↳ è chiamato punto stazionario, cioè quando $\nabla f(x^*) = 0$




- Se $x^* \in \mathbb{R}$ è di minimo locale se $\nabla f(x^*) = 0$ e $\nabla^2 f(x^*)$ (cioè hessiana di f) è semidefinita positiva

METODI DI DISCESA

derivata prima = 0 non sufficiente per definire x punto di minimo \rightarrow serve derivata seconda

Cerchiamo delle direzioni lungo le quali la funzione diminuisce il suo valore



$f(1), f(2), f(3)$ sono curve di livello in cui f diminuisce il suo valore

Le direzioni ci vengono date dai gradienti, perpendicolari alle tangenti calcolate nel punto e curve di livello

Dobbiamo decidere le direzioni lungo le quali la funzione diminuisce il suo valore, e la "step-length" (passo)

$$x_0, x_1, \dots, x_k \xrightarrow{k \rightarrow \infty} x^*$$



p_k è la direzione, d_k il passo

$$x_{k+1} = x_k + d_k \cdot p_k$$

$$\text{ad ogni passo } f(x_{k+1}) < f(x_k) \quad d_k \in \mathbb{R}^+$$

DEF il vettore p è una direzione di discesa in f in x se esiste un $\bar{d} > 0$ tale che

$$f(x + d_p p) < f(x) \quad \forall d \in [0, \bar{d}]$$

LEMMA Sia $f \in C^1$, il vettore p è di discesa in f in x se

$$p^T \nabla f(x) < 0$$

ESEMPIO

$$f(x) = x_1^2 + 3x_2^2$$

$$p = (5, 0) \quad \bar{x} = (1, 1)$$

p è di discesa per f in \bar{x} ?

$$\nabla f(x) = (2x_1, 6x_2)$$

$$\nabla f(\bar{x}) = (2, 6)$$

$$p^T \nabla f(\bar{x}) = \begin{pmatrix} 5 \\ 0 \end{pmatrix} \cdot (2, 6) = 10$$

No, perché $p^T \nabla f(x)$ non è < 0 \rightarrow NO DISCESA

SCELTA DELLA DIREZIONE

Soltanmente si sceglie $p_k = -\nabla f(x_k)$ che equivale alla max direzione di decrescita

$$p_k^T \nabla f(x_k) = -\nabla f(x_k)^T \nabla f(x_k) < 0 \quad \text{sempre}$$

$$\boxed{\begin{aligned} \text{NB} \quad v^T v &= \sum_{i=1}^m v_i \cdot v_i = \sum_{i=1}^m v_i^2 \geq 0 & \|v\|_2^2 \\ -\nabla f(x_k)^T \nabla f(x_k) &= -\|\nabla f(x_k)\|_2^2 \leq 0 \end{aligned}}$$

SCELTA DEL PASSO Se scelgo il passo solo in funzione della condizione $f(x_{k+1}) < f(x_k)$ non è sufficiente

Soltanmente più il passo è piccolo, e più ho garanzia della decrescita della funzione. Ma passi troppo piccoli comportano una convergenza lenta. Il passo fisso non sempre garantisce la convergenza e la decrescita della funzione.

Neanche impone ad ogni iterazione $f(x_{k+1}) < f(x_k)$ è condizione sufficiente alla convergenza

Condizioni di Wolfe

I^o: condizione di Wolfe - Armijo

condizione di decrescita sufficiente. Limite inferiormente la decrescita ad ogni passo

$$f(x_k + \alpha_k p_k) \leq f(x_k) - \alpha_k \gamma$$

dove $\gamma = -\beta_1 \nabla f(x_k)^T p_k$ con $0 < \beta_1 < 1$

$$\rightarrow f(x_{k+1} + \alpha_k p_k) \leq f(x_k) + \alpha_k \beta_1 \nabla f(x_k)^T p_k$$

II^o: condizione di Wolfe

condizione di curvatura. Assicura che non vengono compiuti passi troppo corti

$$\frac{\nabla f(x_k + \alpha_k p_k)^T p_k}{\nabla f(x_k)^T p_k} \leq \beta_2 \quad 0 < \beta_2 < 1$$

$\nabla f(x_{k+1} + \alpha_k p_k)^T p_k \geq \beta_2 \nabla f(x_k)^T p_k$

Uniamo le due condizioni

Posto $\alpha_0 = 1$, lo vedremo fino a trovare un α_k che soddisfa le condizioni di Armijo

Algoritmo di backtracking

① $\bar{d} = 1$, $\rho > 0$, $c \in (0, 1)$, $d \leftarrow \bar{d}$ solitamente $\rho = 1/2$

② while $f(x_k + d p_k) \leq f(x_k) + d \cdot c \cdot \nabla f(x_k)^T p_k$
do $d = d \cdot \rho$ endwhile

③ $d_k = d$ precisione macchina



Nel while si può aggiungere anche una condizione sulla lunghezza di d . Se $|d| < \epsilon \rightarrow \text{STOP}$

Teorema di convergenza:

Supponiamo f limitata inferiormente e differentiabile oltre:

il metodo di discese che calcola gli iterati $x_{k+1} = x_k + \alpha_k p_k$ con p_k direzione di discesa per f in x_k

e α_k calcolato con algoritmo di backtracking, converge a un punto di min o di sella di f ($\nabla f(x^*)$)


FUNZIONI CONVESSE

$f: \mathbb{R}^m \rightarrow \mathbb{R}$ è convessa se

(strettamente convessa)

$$f(tx + (1-t)y) \leq t f(x) + (1-t) f(y) \quad (\Leftarrow)$$

$$\forall t \in [0,1], \forall x,y \in \mathbb{R}^m$$



f convessa tutti i punti compresi tra x, y , sono \leq del segmento che unisce i due punti x, y

Lemme: Se $f \in C^2(\mathbb{R}^m)$, $x \in \mathbb{R}^m$, allora vale

$$f \text{ convessa} \iff \nabla^2 f(x) \text{ è semidefinita positiva} \quad (\text{Hessiana di } f)$$

Teatrino: Se f è convessa un punto di minimo locale è un punto di minimo globale

f convessa \rightarrow ogni punto di minimo locale x^* è minimo globale di f

f strettamente convessa \rightarrow esiste un unico punto di minimo locale (il metodo di discese va verso il minimo)

ES FUNZIONE CONVESA

$$f: \mathbb{R}^m \rightarrow \mathbb{R}$$

$$\min_{x \in \mathbb{R}^m} \underbrace{\|Ax - b\|_2}_f$$

Se A è di rango massimo $\rightarrow f$ è strettamente convessa

$$\nabla f(x) = A^T A x - A^T b = 0 \implies A^T A x = A^T b$$

$$\nabla^2 f(x) = A^T A \quad \text{se } A \text{ è di rango massimo} \rightarrow A^T A \text{ è definita positiva}$$

Altri metodi di discese

Nel metodo di Newton

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)} \quad \left(p_k = -\frac{1}{f'(x_k)}, d_k = f(x_k) \right)$$

Metodi tipo Newton:

$$p_k = - \underbrace{\left(\nabla^2 f(x_k) \right)^{-1}}_{\text{hessiano}} \cdot \nabla f(x_k)$$

Non invertendo la matrice, ma calcolo

calcolo la direzione di discese risolvendo

$$\nabla^2 f(x_k) \cdot p_k = -\nabla f(x_k)$$

Si dimostra che p_k è direzione di discese per f in x_k se $\nabla^2 f(x_k)$ è definita positiva

Ogni iterazione ha una completezza maggiore, con meno iterazioni per la convergenza